

Смеси моделей векторной авторегрессии в задаче прогнозирования временных рядов

Дмитрий Сергеевич Федоряка

Московский физико-технический институт

20 апреля 2017 г.

Цель исследования

Цель

Строить предсказание периодических временных рядов методом векторной авторегрессии

Проблема




Линейная регрессия даёт низкую точность и переобучается

Решение

Построить композицию линейных моделей

- Стрижов, Нейчев, Катруца — Выбор оптимального набора признаков из мультикоррелирующего множества в задаче прогнозирования, 2015
- Bishop — Pattern Recognition and Machine Learning, 2006
- Freund Y., Schapire R. E — Experiments with a new boosting algorithm, 1996

Работа в одном слайде



Постановка задачи

Набор временных рядов:

$$\mathcal{D} = \{s_1, s_2, \dots, s_p\}$$

$$s_i = \{s_i(\Delta t_i), s_i(2\Delta t_i), \dots, s_i(L_i\Delta t_i)\} = \{s_i^1, s_i^2, \dots, s_i^{L_i}\}$$

Прогноз:

$$f(\mathcal{D}) = \{\hat{s}_1^{L_1-r+1}, \hat{s}_1^{L_1-r+2}, \dots, \hat{s}_1^{L_1}\}$$


Функция потерь:

$$S(f) = \sum_{i=L_1-r+1}^{L_1} (s_1^i - \hat{s}_1^i)^2$$

Задача прогнозирования:

$$f^* = \arg \min_f S(f, \mathcal{D})$$

Решение: сведение к задаче регрессии



$$f^* = \arg \min_f \sum_{j=1}^{m-1} \|f(X_j) - Y_j\|_2^2$$

Линейная модель:

$$f(\mathbf{x}) = \mathbf{x}W$$

W - матрица коэффициентов:

$$W = X^+Y = (X^T X)^{-1} X^T Y$$

Проблемы:

- низкая точность
- переобучение

Композиция моделей:

$$f(\mathbf{x}) = \sum_{i=1}^K \pi_i(\mathbf{x}) f_i(\mathbf{x})$$

Алгоритмы:

- Бэггинг и метод случайных подпространств
- Адаптивный бустинг
- Кластерная регрессия


Кластерная регрессия

Гипотеза: обучающая выборка разбивается на кластеры, так что объекты i -го класса описываются некоторой своей моделью f_i :

$$\overline{1, m} = \bigsqcup_{j=1}^K C_j$$

Предложение: использовать эти модели как базовые модели смеси экспертов.

Алгоритм кластеризации K-means



Центры \rightarrow модели

Поиск центров \rightarrow обучение моделей

Ближайший центр \rightarrow наиболее точно описывающая объект модель

Кластерная регрессия: обучение

$\forall j \in \overline{1, m} \ C_j = \text{rand}(1, m)$

для $iter \in \overline{1, N_{it}}$

для $j \in \overline{1, K}$

Обучаем модель f_j на объектах с индексами C_j .

для $i \in \overline{1, m}$

для $j \in \overline{1, K}$

$$S(i, j) = \|f_j(X_i) - Y_i\|$$

для $i \in \overline{1, m}$

для $j \in \overline{1, K}$

$$C_j = \{i \in \overline{1, m} \mid \underset{k}{\operatorname{argmin}}(S(i, k)) = j\}$$

Кластерная регрессия: предсказание

Обучаем алгоритм f_0 на всей выборке.

$\tilde{Y}^0 = f_0(X^0)$ — предварительный ответ.


$\forall j \in \overline{1, K} \pi'_j = \mathfrak{E}\left(\frac{\|f_j(X^0) - Y^0\|}{\|\tilde{Y}^0\|}\right)$ — вычисление вероятностей.

$\forall j \in \overline{1, K} \pi_j = \frac{\pi'_j}{\sum_{k=1}^K \pi'_k}$ — нормировка.


$Y^0 = \sum_{j=1}^K \pi_j \cdot f_j(X^0)$ — ответ.

Примеры возможных функций $\mathfrak{E}(S)$: $\frac{1}{S+\varepsilon}$, e^{-S} , $1 - \frac{1}{1+e^{-S}}$



Турция - потребление энергии



Германия - рыночные цены на электричество




Ошибки предсказаний



	Турция 1	Турция 2	Германия 1	Германия 2	Польша
Лин. рег.	6.3%	4.0%	30.1%	28.8%	2.0%
Бустинг	3.8%	3.6%	24.1%	23.0%	3.6%
Бэггинг	3.6%	3.0%	27.5%	26.4%	1.7%

$$MSE(\hat{s}) = \frac{\sqrt{\langle (s_1 - \hat{s}_1)^2 \rangle}}{\langle s_1 \rangle} = \frac{1}{\sqrt{r}} \frac{\sqrt{\sum_i (s_i^1 - \hat{s}_i^1)^2}}{\sum_i s_i^1}$$

Зависимость ошибки от числа базовых моделей



Заключение

- Задача прогнозирования временных рядов с периодичностью сведена к задаче регрессии.
- Задача регрессии решается с помощью линейной модели.
- Построены композиции моделей (бэггинг и бустинг), повышающие точность прогноза.
- Предложен эвристический итерационный алгоритм композиции моделей, который не оказался эффективным в данной задаче из-за его требований к размеру обучающей выборки и из-за свойств временных рядов.